Devoir maison Algorithmes stochastiques

BOUACHA LAZHAR

8 Novembre 2020

Partie théorique

Question 1:

La proportion d'étudiants qui répond 1 à la question m peut s'écrire

$$q_m = \frac{1}{N} \sum_{n=1}^{N} x_{n,m}.$$

Si cette proposition est supérieure à 0.5, il y a une majorité d'étudiants ayant répondu 1 à la question m. Sinon il y a une majorité d'étudiants ayant répondu 0 à la question m. On en déduit des estimateurs \hat{t}_m des vraies réponses aux questions

$$t_m = \left\{ \begin{array}{ll} 1 & \text{si, } q_m > 0.5 \text{ une majorit\'e d'\'el\`eves a r\'epondu 1 \`a la question } m \\ 0 & \text{sinon.} \end{array} \right.$$

Question 2:

On note
$$F(\mathbf{x}, \mathbf{t}, \theta) = \log p(\forall m, T_m = t_m, \text{ et } \forall n, m, X_{n,m} = x_{n,m} | \theta).$$

Les réponses aux différentes questions sont indépendantes, donc on peut

écrire,
$$F(\mathbf{x}, \mathbf{t}, \theta) = \log \prod_{m=1}^{M} p(T_m = t_m, \text{ et } \forall n, X_{n,m} = x_{n,m} | \theta)$$

 $\overline{m=1}$ En utilisant la formule de Bayes, on obtient ensuite :

$$F(\mathbf{x}, \mathbf{t}, \theta) = \log \prod_{m=1}^{M} p(\forall n, X_{n,m} = x_{n,m} | T_m = t_m, \theta) p(T_m = t_m)$$
 (1)

$$= M \log 0.5 + \log \prod_{m=1}^{M} p(\forall n, X_{n,m} = x_{n,m} | T_m = t_m, \theta)$$
 (2)

Puis par indépendance des réponses des élèves entre elles, et en remarquant que

$$p(X_{n,m} = x_{n,m} | T_m = t_m, \theta) = \theta_n^{\mathbf{1}_{x_{n,m}=t_m}} (1 - \theta_n)^{\mathbf{1}_{x_{n,m}=1-t_m}},$$

$$F(\mathbf{x}, \mathbf{t}, \theta) = M \log 0.5 + \log \prod_{m=1}^{M} \prod_{n=1}^{N} p(X_{n,m} = x_{n,m} | T_m = t_m, \theta)$$
 (3)

$$= M \log 0.5 + \sum_{n=1}^{N} \sum_{m=1}^{M} \log \left(\theta_n^{\mathbf{1}_{x_{n,m}=t_m}} (1 - \theta_n)^{\mathbf{1}_{x_{n,m}=1-t_m}} \right)$$
 (4)

Question 3:

$$a = 1 : \mathbf{1}_{a=1} = 1 + (1-1)(1-1) = 1$$

 $a = 0 : \mathbf{1}_{a=0} = 0 + (1-0)(1-0) = 1$

Question 4:

Lorsqu'on dérive $F(\mathbf{x}, \mathbf{t}, \theta)$ par rapport θ_n on obtient

$$\frac{\partial F}{\partial \theta_n} = \sum_{m=1}^{M} \left(\frac{1_{x_{n,m}=t_m}}{\theta_n} - \frac{1_{x_{n,m}=1-t_m}}{1-\theta_n} \right)$$

En regardant les points d'annulation de cette dérivée on en déduit l'estimateur suivant pour θ_n :

$$\hat{\theta}_n = \frac{1}{M} \sum_{m=1}^M \mathbf{1}_{x_{n,m}=t_m} = \frac{1}{M} \sum_{m=1}^M (x_{n,m} t_m + (1 - x_{n,m})(1 - t_m))$$

Question 5:

On remarque que :

$$\mathbb{E}[T_m|\mathbf{x},\theta] = \mathbb{P}[T_m = 1|\mathbf{x},\theta] = \frac{\mathbb{P}[T_m = 1 \text{ et } \mathbf{x} = x|\theta]}{\mathbb{P}[\mathbf{x} = x|\theta]}$$
(5)

$$= \frac{\mathbb{P}[T_m = 1 \text{ et } \mathbf{x} = x|\theta]}{\mathbb{P}[T_m = 1 \text{ et } \mathbf{x} = x|\theta] + \mathbb{P}[T_m = 0 \text{ et } \mathbf{x} = x|\theta]}$$
(6)

Donc on a

$$\mathbb{P}[T_m = 1 \text{ et } \mathbf{x} = x | \theta] = \mathbb{P}[\mathbf{x} = x | T_m = 1, \theta] \mathbb{P}[T_m = 1]$$
 (7)

$$=0.5\prod_{n=1}^{N}\theta_{n}^{x_{n,m}}(1-\theta_{n})^{1-x_{n,m}}$$
(8)

$$\mathbb{P}[T_m = 0 \text{ et } \mathbf{x} = x | \theta] = \mathbb{P}[\mathbf{x} = x | T_m = 0, \theta] \mathbb{P}[T_m = 0]$$
(9)

$$=0.5\prod_{n=1}^{N}\theta_{n}^{1-x_{n,m}}(1-\theta_{n})^{x_{n,m}}$$
(10)

Question 6:

- 1. Initialiser les estimateurs de \mathbf{t} , $t_m = \begin{cases} 1 & \text{si } q_m > 0.5 \\ 0 & \text{sinon.} \end{cases}$
- 2. Pour i allant de 1 à N_{iter} (nombre d'itérations de l'algorithme)
- Étape M : mettre à jour le vecteur θ avec pour tout n allant de 1 à N

$$\theta_n = \frac{1}{M} \sum_{m=1}^{M} (x_{n,m} t_m + (1 - x_{n,m})(1 - t_m))$$

- Étape E : mettre à jour le vecteur \mathbf{t} , avec pour tout m allant de 1 à M

$$t_m = \frac{\prod_{n=1}^N \theta_n^{x_{n,m}} (1 - \theta_n)^{1 - x_{n,m}}}{\prod_{n=1}^N \theta_n^{x_{n,m}} (1 - \theta_n)^{1 - x_{n,m}} + \prod_{n=1}^N \theta_n^{1 - x_{n,m}} (1 - \theta_n)^{x_{n,m}}}$$

3. A la fin de l'algorithme, seuiller tous les coefficients du vecteur ${\bf t}$ (qui prend ses valeurs entre 0 et 1) à 0.5 pour obtenir un vecteur binaire.